



CTU

CZECH TECHNICAL
UNIVERSITY
IN PRAGUE

POKROČILÉ METODY KLASIFIKACE FAKE NEWS S VYUŽITÍM VELKÝCH JAZYKOVÝCH MODELŮ

Nikita Bardatskii



Cíle

- Seznámit se s předchozí prací Jana Flajžíka zaměřenou na detekci falešných zpráv
- Prozkoumat nové metody zpracování přirozeného jazyka (NLP) pro zlepšení klasifikace na poskytnutých datových sadách
- Provést experimenty s pokročilými NLP modely (BERT, GPT-2 apod.)
- Porovnat dosažené výsledky s předchozí prací




Metodika

- Prostudovat nejnovější odborné články zaměřené na detekci falešných zpráv
- Vybrat pokročilejší metody
- Provést experimenty
- Porovnat výsledky s předchozí prací
- Zhodnotit vlastní přínos oproti předchozí práci a navrhnout možná zlepšení


Analýza Datových Sad

- 3 anglické, 1 český dataset
- Relativně dlouhé články, pouze jeden dataset má krátké články
- Rozšířená vizualizace dat
- Analýza tokenizace

Label Balance in ReCOVeRY Dataset



Distribution by Label (overlapped)




Analýza Datových Sad


- 3 anglické, 1 český dataset
- Relativně dlouhé články, pouze jeden dataset má krátké články
- Rozšířená vizualizace dat
- Analýza tokenizace

* Datové sady byly převzaty z původní bakalářské práce.

Label Balance in ReCOVeRY Dataset



Distribution by Label (overlapped)



Použité modely

- BERT
 - Encoderová transformerová architektura
 - Využívá obousměrný kontext (levý i pravý)
 - Referenční model pro klasifikaci textu

Použité modely

- BERT
 - Encoderová transformerová architektura
 - Využívá obousměrný kontext (levý i pravý)
 - Referenční model pro klasifikaci textu
- DistilBERT
 - Zjednodušená verze BERTu vytvořená metodou knowledge distillation
 - Přibližně o 40 % menší a o 60 % rychlejší
 - Zachovává většinu výkonnosti BERTu

Použité modely

- BERT
 - Encoderová transformerová architektura
 - Využívá obousměrný kontext (levý i pravý)
 - Referenční model pro klasifikaci textu
- DistilBERT
 - Zjednodušená verze BERTu vytvořená metodou knowledge distillation
 - Přibližně o 40 % menší a o 60 % rychlejší
 - Zachovává většinu výkonnosti BERTu
- RoBERTa
 - Optimalizovaná varianta BERTu
 - Trénována na větším množství dat
 - Používá techniky pro zlepšení robustnosti modelu

Použité modely


- BERT
 - Encoderová transformerová architektura
 - Využívá obousměrný kontext (levý i pravý)
 - Referenční model pro klasifikaci textu
- DistilBERT
 - Zjednodušená verze BERTu vytvořená metodou knowledge distillation
 - Přibližně o 40 % menší a o 60 % rychlejší
 - Zachovává většinu výkonnosti BERTu
- RoBERTa
 - Optimalizovaná varianta BERTu
 - Trénována na větším množství dat
 - Používá techniky pro zlepšení robustnosti modelu
- GPT-2
 - Decoderová transformerová architektura
 - Predikuje další token na základě předchozího kontextu
 - Primárně určen pro generování textu




Implementace




Implementace



Implementace



Implementace



Standardní
ML a DS
nástroje
(scikit, pytorch, scipy,
nltk)

Implementace



+



+

Standardní
ML a DS
nástroje
(scikit, pytorch, scipy,
nltk)

Ukládání a
zaznamenávání

Implementace



+




+

Standardní
ML a DS
nástroje


(scikit, pytorch, scipy,
nltk)

Ukládání a
zaznamenávání



MLflow

Implementace



* assets, images, templates and helper files are excluded

Prezentace výsledků



Výsledky pro ReCOVery Dataset:

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	FPR	FNR
BERT	0.995	0.995	0.995	0.995	1.000	0.006	0.005
DistillIBERT	0.989	0.987	0.991	0.989	0.997	0.014	0.009
RoBERTa	0.989	0.986	0.994	0.990	0.999	0.015	0.006
GPT1	0.987	0.990	0.985	0.988	0.999	0.012	0.015
GPT2	0.990	0.989	0.991	0.990	0.999	0.011	0.009

Výsledky pro nejlepší model BERT:

Hyperparameter	Value
epochs	10
batch_size	16
eval_batch_size	16
learning_rate	0.000
lr_scheduler	linear
weight_decay	0.000
optimizer	adamw_torch
early_stopping_patience	3
early_stopping_threshold	0.010

Parameter	Value
pipeline_name	minimal
step_0	bert_base_uncased_encoder



Prezentace výsledků



Výsledky pro ReCOVery Dataset:

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	FPR	FNR
BERT	0.995	0.995	0.995	0.995	1.000	0.006	0.005
DistillIBERT	0.989	0.987	0.991	0.989	0.997	0.014	0.009
RoBERTa	0.989	0.986	0.994	0.990	0.999	0.015	0.006
GPT1	0.987	0.990	0.985	0.988	0.999	0.012	0.015
GPT2	0.990	0.989	0.991	0.990	0.999	0.011	0.009

Výsledky pro nejlepší model BERT:

Hyperparameter	Value
epochs	10
batch_size	16
eval_batch_size	16
learning_rate	0.000
lr_scheduler	linear
weight_decay	0.000
optimizer	adamw_torch
early_stopping_patience	3
early_stopping_threshold	0.010

Parameter	Value
pipeline_name	minimal
step_0	bert_base_uncased_encoder



* tabulky hyperparametrů, ROC Křivka a Matice záměn jsou součástí zdrojových kódů

Porovnání s předchozí prací

ISOT

Model	Accuracy	Precision	Recall	F1-Score
Naive Bayes	0.954	0.944	0.966	0.955
Random Forest	0.929	0.991	0.891	0.938
CNN	0.974	0.987	0.965	0.976
LSTM	0.656	0.674	0.686	0.680

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	FPR	FNR
BERT	0.995	0.995	0.995	0.995	1.000	0.006	0.005
DistillliBERT	0.989	0.987	0.991	0.989	0.997	0.014	0.009
RoBERTa	0.989	0.986	0.994	0.990	0.999	0.015	0.006
GPT1	0.987	0.990	0.985	0.988	0.999	0.012	0.015
GPT2	0.990	0.989	0.991	0.990	0.999	0.011	0.009

EUvsDisinfo

Model	Accuracy	Precision	Recall	F1-Score
Naive Bayes	0.909	0.947	0.875	0.910
Random Forest	0.941	0.936	0.939	0.937
CNN	0.945	0.961	0.935	0.947
LSTM	0.951	0.933	0.966	0.949

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	FPR	FNR
BERT	1.000	1.000	1.000	1.000	1.000	0.000	0.000
DistillliBERT	0.978	0.956	1.000	0.977	1.000	0.041	0.000
RoBERTa	0.991	1.000	0.983	0.991	1.000	0.000	0.017
GPT1	0.984	1.000	0.973	0.986	0.999	0.000	0.027
GPT2	0.981	0.982	0.982	0.982	0.998	0.019	0.018

ReCOVery

Model	Accuracy	Precision	Recall	F1-Score
Naive Bayes	0.835	0.941	0.834	0.884
Random Forest	0.794	0.956	0.781	0.860
CNN	0.781	0.932	0.779	0.849
LSTM	0.695	0.927	0.709	0.803

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	FPR	FNR
BERT	0.905	0.898	0.971	0.933	0.940	0.237	0.029
DistillliBERT	0.866	0.908	0.895	0.901	0.919	0.198	0.105
RoBERTa	0.807	0.818	0.917	0.865	0.850	0.424	0.083
GPT1	0.833	0.880	0.876	0.878	0.889	0.263	0.124
GPT2	0.843	0.886	0.877	0.882	0.912	0.228	0.123

Czech Dataset

Model	Accuracy	Precision	Recall	F1-Score
Naive Bayes	0.899	0.907	0.922	0.915
Random Forest	0.831	1.000	0.778	0.875
CNN	0.801	0.812	0.831	0.821
LSTM	0.749	0.672	0.903	0.771

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	FPR	FNR
BERT	0.847	0.811	0.966	0.882	0.918	0.328	0.034
DistillliBERT	0.920	0.901	0.965	0.932	0.978	0.138	0.035
RoBERTa	0.613	0.613	1.000	0.760	0.775	1.000	0.000
GPT1	0.780	0.787	0.895	0.837	0.826	0.418	0.105
GPT2	0.793	0.787	0.871	0.827	0.865	0.308	0.129

Porovnání s předchozí prací

- **ISOT:**
 - Nejlepší model: **BERT**
 - Accuracy: **90,5% oprotí 83,5%** u Naive Bayes

Porovnání s předchozí prací

- **ISOT:**
 - Nejlepší model: **BERT**
 - Accuracy: **90,5% oprotí 83,5%** u Naive Bayes
- **ReCOVery:**
 - Nejlepší model: **BERT**
 - Accuracy: **99,5% oproti 97%** u CNN

Porovnání s předchozí prací

- **ISOT:**
 - Nejlepší model: **BERT**
 - Accuracy: **90,5% oproti 83,5%** u Naive Bayes
- **ReCOVery:**
 - Nejlepší model: **BERT**
 - Accuracy: **99,5% oproti 97%** u CNN
- **EUvsDisinfo:**
 - Nejlepší model: **BERT**
 - Accuracy: **100% oproti 95,1%** u LSTM

Porovnání s předchozí prací

- **ISOT:**
 - Nejlepší model: **BERT**
 - Accuracy: **90,5% oprotí 83,5%** u Naive Bayes
- **ReCOVery:**
 - Nejlepší model: **BERT**
 - Accuracy: **99,5% oproti 97%** u CNN
- **EUvsDisinfo:**
 - Nejlepší model: **BERT**
 - Accuracy: **100% oproti 95,1%** u LSTM
- **Česká datová sada:**
 - Nejlepší model: **DistilBERT**
 - Accuracy: **92% oproti 89,9%** u Naive Bayes

Závěr

- Byly provedeny experimenty s pokročilými NLP modely a jejich výsledky byly porovnány s výsledky předchozí práce
- Bylo identifikováno několik možností pro další zlepšení efektivity klasifikace:
 - Zvládnout problém s omezeným vstupem
 - Soustředit se na menší modely
 - Zkusit Mixture of Experts
 - Zkusit Claim extraction + Retrieval + Evidence ranking
 - Pokročit na jiné, těžší datasety
 - Zaměření na uplatnění v open source a kontrola alignmentu.
- Byl vytvořen framework pro provádění experimentů, který vyžaduje pouze rozšíření o další modely a metody.

Děkuji za pozornost